


TEMA 7: TEORÍA DE COLAS – PRÁCTICA 1

Existen múltiples situaciones organizativas en las que se producen colas de espera debido a que existen varios **clientes** que utilizan uno o varios **servidores** (máquinas, cabinas de peaje...). Este tipo de sistemas se agrupan bajo el nombre genérico de **colas o líneas de espera**. Cada cola consta de un número finito (generalmente bajo) de servidores que suelen estar agrupados en un centro de servicio. Debido al carácter aleatorio de la llegada de clientes y de los tiempos de servicio, es posible que los clientes soporten una espera hasta el momento de ser atendidos.

El estudio de colas determina las medidas de funcionamiento de una situación de colas, incluyendo el tiempo de espera y la longitud promedio de la cola, entre otras. Esta información puede servir a una organización o persona para la toma de decisiones.

El modelo de cola más simple es el representado en la figura, donde los clientes llegan a la entrada procedentes de un manantial finito o infinito y esperan en la cola hasta ser atendidos en el canal de servicio. Tras ser atendidos, los usuarios siguen adelante, hacia un nuevo punto de servicio o hacia la salida.



Con el objeto de simplificar los diferentes modelos de colas que pueden darse, se suelen representar mediante el siguiente esquema:

$$X / Y / s / K / A / B$$

donde

- **X**: Es la distribución de llegada de los clientes (lapso de tiempo entre dos llegadas sucesivas).

Existen diferentes tipos de tiempo entre llegadas:

- Determinista (D): los clientes sucesivos llegan en un mismo intervalo de tiempo, fijo y conocido.
- Probabilístico: el tiempo entre llegadas sucesivas es incierto y variable. Dentro de este tipo, puede ocurrir que la distribución de los tiempos entre llegadas sea exponencial o Poisson (M) o que sea una distribución genérica (G).

- **Y**: Es la distribución servicio (tiempo en el que son atendidos los clientes). Existen diferentes tipos

- Determinista (D): tiempo de servicio fijo y conocido.
- Probabilístico: tiempo de servicio incierto y variable. Dentro de este tipo, puede ocurrir que la distribución de los tiempos de servicio sea exponencial (M) o genérica (G).

- **s**: Es el número de canales de servicio en paralelo (servidores). Es un valor numérico.

- **K**: Es la capacidad de la cola (número máximo de clientes permitidos en la cola más en el servicio). Es un valor numérico y el valor por defecto es ∞ .

- **A:** Es el tamaño de la población. Es un valor numérico y el valor por defecto es ∞ .
- **B:** Es la disciplina de servicio (orden de selección de los clientes). Existen diferentes tipos:
 - FIFO (*first in-first out*) : primero en llegar-primero en ser atendido o salir.
 - LIFO (*last in-first out*): último en llegar-primero en ser servido.
 - SIRO (*service in random order*): orden de servicio aleatorio.
 - GD (*general service discipline*): disciplina de servicio general.
 - RR (*round robin*): el cliente es servido durante un lapso fijo de tiempo y debe reingresar en la cola si no se han satisfecho sus demandas (redes de ordenadores).

El valor por defecto de la disciplina de servicio es FIFO.

Por ejemplo, la notación M/D/1/ ∞ / ∞ /FIFO hace referencia a una cola con distribución de llegadas de Poisson, tiempo de servicio determinista, un único servidor, sin límite en el número de clientes en el sistema, potencial población infinita y disciplina de servicio FIFO. Como todos los valores, a partir del tercero, son los asignados por defecto, la notación anterior se abrevia como M/D/1.

El funcionamiento o rendimiento de una cola se mide en función de varias características. Las de mayor relevancia son:

- **N :** variable aleatoria que representa el número de clientes en el sistema (en la cola más en servicio).
- **N_q :** variable aleatoria que representa el número de clientes en la cola.
- **T :** variable aleatoria que describe el tiempo que un cliente pasa en el sistema.
- **T_q :** variable aleatoria que describe el tiempo que un cliente pasa en la cola.
- **P_n :** probabilidad de que exactamente n clientes se encuentren en el sistema.
- **L :** número medio de clientes en el sistema (cola + servicio).
- **L_q :** número de clientes en la cola (a la espera de ser servidos).
- **W :** tiempo medio para cada cliente en el sistema (cola + servicio).
- **W_q :** tiempo medio de espera por cliente en la cola.

Por otra parte, la circulación en el sistema viene dada por:

- **λ :** tasa media de llegadas de clientes, constante para todo n .
- **μ :** tasa media de servicio de clientes, constante para todo n .
- **λ_n :** tasa media de llegadas de clientes cuando hay n clientes en el sistema.
- **μ_n :** tasa media de servicio cuando hay n clientes en el sistema.
- **$\rho = \frac{\lambda}{\mu}$:** factor de utilización o intensidad de tráfico. El valor de ρ debe ser menor que 1, ya que si vale 1 se produce un colapso en la cola.

➤ Modelo M/M/1

Se trata de una cola en la que la distribución entre llegadas consecutivas de clientes es exponencial de parámetro λ (llegadas aleatorias, o sea según un proceso de Poisson), la distribución de los tiempos de

servicio es exponencial de parámetro μ y sin limitación en el número de clientes en el sistema.

Por tanto, las principales medidas de rendimiento son:

$$P_0 = 1 - \rho$$

$$P_n = \rho^n P_0$$

$$L_q = \frac{\rho^2}{1 - \rho}$$

$$L = \rho + L_q = \frac{\rho}{1 - \rho}$$

$$W_q = \frac{\rho}{\mu(1 - \rho)}$$

$$W = W_q + \frac{1}{\mu} = \frac{1}{\mu(1 - \rho)}$$

La probabilidad de que haya al menos un cliente en el sistema (probabilidad de que un cliente tenga que esperar) es

$$P(N > 0) = 1 - P_0 = \rho$$

La probabilidad de que haya más de n clientes en el sistema es

$$P(N > n) = \rho^{n+1}$$

La probabilidad de que el servidor esté ocioso o probabilidad de espera nula es

$$P(N = 0) = P_0 = 1 - \rho$$

Las varianzas de las variables aleatorias N y T_q son, respectivamente,

$$\sigma^2(N) = \frac{\rho}{(1 - \rho)^2} \quad \sigma^2(T_q) = \frac{2\rho - \rho^2}{\mu^2(1 - \rho)^2}$$

La función de distribución del tiempo T de permanencia en el sistema es

$$P(T \leq t) = 1 - e^{-\mu t(1 - \rho)}$$

La función de distribución de la variable aleatoria T_q que representa el tiempo de espera en la cola es

$$P(T_q \leq t) = 1 - \rho e^{-\mu t(1 - \rho)}$$

EJEMPLO DE COLA MODELO M/M/1

Si los clientes llegan a un teléfono público según un proceso de Poisson con una tasa de 1 cliente cada 15 minutos (4 por hora) y la duración media de cada llamada es de 5 minutos (tasa de 12 clientes por hora, con distribución de los tiempos de servicio exponencial), determinar:

- 1) Probabilidad de que un cliente nuevo tenga que esperar más de 10 minutos (1/6 horas) antes de acceder al teléfono.
- 2) Probabilidad de que haya más de 3 personas en la cola (4 en el sistema).
- 3) Probabilidad de que un cliente tenga que esperar más de 10 minutos (1/6 horas) en completar su llamada.
- 4) Función de probabilidad de la variable aleatoria N que representa el número de clientes en el sistema.


Solución:

	A	B	C	D
1		M/M/1 Cola infinita - Población infinita		
2				
3		Tasa de llegadas	4	= "por " & C5
4		Tasa de servicio	12	= "por " & C5
5		Unidad de tiempo	hora	
6				
7		Utilización (intensidad de tráfico)	=C3/C4	
8		P(0)= Probabilidad de ningún cliente en el sistema	=1-C7	
9		Probabilidad de algún cliente en el sistema	=C7	
10		Lq	=C7^2/(1-C7)	
11		L	=C7/(1-C7)	
12		Wq	=C7/(C4*(1-C7))	=C5&"s"
13		W	=C12+1/C4	=C5&"s"
14				
15		Tiempo de espera en la cola t	=1/6	
16		Probabilidad de espera en la cola > t	=C7*EXP(-C4*C15*(1-C7))	
17		Número de clientes n	4	
18		Probabilidad de número de clientes > n	=C7^(C17+1)	
19		Tiempo de permanencia en el sistema t	=1/6	
20		Probabilidad de permanencia en el sistema ≤ t	=1-EXP(-C4*C19*(1-C7))	
21		Probabilidad de permanencia en el sistema > t	=1-C20	


	A	B	C	D
1		M/M/1 Cola infinita - Población infinita		
2				
3		Tasa de llegadas	4	por hora
4		Tasa de servicio	12	por hora
5		Unidad de tiempo	hora	
6				
7		Utilización (intensidad de tráfico)	0,33333333	
8		P(0)= Probabilidad de ningún cliente en el sistema	0,66666667	
9		Probabilidad de algún cliente en el sistema	0,33333333	
10		Lq	0,16666667	
11		L	0,5	
12		Wq	0,04166667	horas
13		W	0,125	horas
14				
15		Tiempo de espera en la cola t	0,16666667	
16		Probabilidad de espera en la cola > t	0,08786571	
17		Número de clientes n	4	
18		Probabilidad de número de clientes > n	0,00411523	
19		Tiempo de permanencia en el sistema t	0,16666667	
20		Probabilidad de permanencia en el sistema ≤ t	0,73640286	
21		Probabilidad de permanencia en el sistema > t	0,26359714	
22				

	A	B	C	D	E	F
1		M/M/1 Cola infinita - Población infinita				
2						
3		Tasa de llegadas	4	= "por "&C5		
4		Tasa de servicio	12	= "por "&C5		
5		Unidad de tiempo	hora			
6						
7		Utilización (intensidad de tráfico)	=C3/C4		n	P(n)
8		P(0)= Probabilidad de ningún cliente en el sistema	=1-C7		0	=C8
9		Probabilidad de algún cliente en el sistema	=C7		1	=(C7^E9)*C8
10		Lq	=C7^2/(1-C7)		2	=(C7^E10)*C8
11		L	=C7/(1-C7)		3	=(C7^E11)*C8
12		Wq	=C7/(C4*(1-C7))	=C5&"s"	4	=(C7^E12)*C8
13		W	=C12+1/C4	=C5&"s"	5	=(C7^E13)*C8
14					6	=(C7^E14)*C8
15		Tiempo de espera en la cola t	=1/6		7	=(C7^E15)*C8
16		Probabilidad de espera en la cola > t	=C7*EXP(-C4*C15*(1-C7))		8	=(C7^E16)*C8
17		Número de clientes n	4		9	=(C7^E17)*C8
18		Probabilidad de número de clientes > n	=C7^(C17+1)		10	=(C7^E18)*C8
19		Tiempo de permanencia en el sistema t	=1/6			
20		Probabilidad de permanencia en el sistema ≤ t	=1-EXP(-C4*C19*(1-C7))			
21		Probabilidad de permanencia en el sistema > t	=1-C20			
22						

	A	B	C	D	E	F	G	H	I	J
1		M/M/1 Cola infinita - Población infinita	Recorte rectangular							
2										
3		Tasa de llegadas	4	por hora						
4		Tasa de servicio	12	por hora						
5		Unidad de tiempo	hora							
6										
7		Utilización (intensidad de tráfico)	0,33333333		n	P(n)				
8		P(0)= Probabilidad de ningún cliente en el sistema	0,66666667		0	0,66666667				
9		Probabilidad de algún cliente en el sistema	0,33333333		1	0,22222222				
10		Lq	0,16666667		2	0,074074074				
11		L	0,5		3	0,024691358				
12		Wq	0,04166667	horas	4	0,008230453				
13		W	0,125	horas	5	0,002743484				
14					6	0,000914495				
15		Tiempo de espera en la cola t	0,16666667		7	0,000304832				
16		Probabilidad de espera en la cola > t	0,08786571		8	0,000101611				
17		Número de clientes n	4		9	3,38702E-05				
18		Probabilidad de número de clientes > n	0,00411523		10	1,12901E-05				
19		Tiempo de permanencia en el sistema t	0,16666667							
20		Probabilidad de permanencia en el sistema ≤ t	0,73640286							
21		Probabilidad de permanencia en el sistema > t	0,26359714							
22										
23										
24										
25										
26										
27										
28										
29										
30										
31										
32										
33										
34										



La distribución de probabilidades del número de clientes en el sistema es la reflejada en el gráfico:



CONCLUSIONES

- 1) La probabilidad de que un cliente nuevo tenga que esperar más de 10 minutos antes de acceder al teléfono es muy baja (0.08787).
- 2) La probabilidad de que haya más de 3 personas en la cola (4 en el sistema) es casi nula (0.00412).
- 3) La probabilidad de que un cliente tenga que esperar más de 10 minutos en completar su llamada es de 0.2636.

➤ Modelo M/M/s

En este modelo se consideran s canales de servicio o servidores. La condición de cola estable es $\rho^* < 1$, donde $\rho^* = \frac{\lambda}{s\mu}$ se conoce como intensidad global de tráfico.

Las principales medidas de rendimiento son:

$$P_0 = \frac{1}{\frac{\rho^s}{s!(1-\rho^*)} + \sum_{k=0}^{s-1} \frac{\rho^k}{k!}}$$

$$P_n = \begin{cases} \frac{\rho}{n} P_{n-1} = P_0 \frac{\rho^n}{n!} & \text{si } 1 \leq n \leq s \\ (\rho^*)^{n-s} P_s & \text{si } n > s \end{cases}$$

$$L = \rho + \frac{\rho^*}{(1-\rho^*)^2} P_s$$

$$L_q = L - \rho$$

$$W_q = \frac{P_s}{s\mu(1-\rho^*)^2}$$

$$W = W_q + \frac{1}{\mu}$$

La varianza del tiempo de espera en la cola es

$$\sigma^2(t_q) = \frac{(2 - 2\rho^* - P_s)P_s}{(s\mu)^2(1-\rho^*)^4}$$

El número medio de servidores desocupados es

$$s - \rho$$

La probabilidad de hacer cola, es decir la probabilidad de que haya s o más clientes en el sistema es (*fórmula de Erlang*)

$$P(N \geq s) = \frac{\rho^s}{s!(1-\rho^*)} P_0$$

La función de distribución del tiempo de espera en la cola T_q es

$$P(T \leq t) = 1 - \frac{P_s e^{-\mu t(s-\rho)}}{1-\rho^*}$$

EJEMPLO DE COLA MODELO M/M/s

El peaje de una autopista posee 5 servidores automáticos siendo los tiempos de servicio exponenciales de media 1 minuto (tasa de 60 clientes por hora). Si la llegada de vehículos sigue una distribución de Poisson, de media 299 por hora ¿Será necesario instalar dos servidores más con el fin de reducir el tiempo medio de espera de sus usuarios y mejorar su opinión sobre el servicio prestado por la autopista?

➤ Modelo M/G/1

Las dos modelos anteriores eran **colas de Poisson**, pues tanto la distribución de los tiempos entre llegadas como la de los tiempos de servicio era exponencial. Esta última suposición no suele responder muy bien en la mayoría de las situaciones prácticas pues, con frecuencia, los tiempos de servicios reales se desvían bastante del modelo exponencial, sobre todo cuando los requerimientos de los clientes son muy similares. Desgraciadamente el estudio analítico de las colas con distribuciones no exponenciales es mucho más complicado, aunque se han podido obtener algunos resultados útiles para ciertos modelos.

En el modelo M/G/1 se supone que el proceso de llegadas es Poisson de parámetro λ (tiempos entre llegadas exponenciales), tiempos de servicio con distribución arbitraria y un único servidor. Si se conocen la media $1/\mu$ y la varianza σ^2 de la distribución de tiempos de servicio, entonces, para cuando en algún momento se alcance la condición de estado estable $\rho = \frac{\lambda}{\mu} < 1$, se pueden establecer los siguientes resultados:

$$P_0 = 1 - \rho$$
$$L_q = \frac{\lambda^2 \sigma^2 + \rho^2}{2(1 - \rho)}$$

Esta última es la **fórmula de Pollaczek-Kyntchine** y es uno de los resultados más importantes de la teoría de colas, debido al predominio de los sistemas M/G/1 en la práctica. Además,

$$L = \rho + L_q$$
$$W_q = \frac{\lambda(\sigma^2 + \frac{1}{\mu^2})}{2(1 - \rho)}$$
$$W = \frac{1}{\mu} + W_q$$

Nótese que si σ^2 disminuye, disminuyen los valores anteriores. Esto significa que la consistencia del servicios tiene mucha transcendencia en el desempeño del sistema.

EJEMPLO DE COLA MODELO M/G/1

La distribución de los tiempos de consulta de un médico tiene una media de 12 minutos por paciente (0,2 horas), siendo su desviación típica 24 minutos (0,4 horas). Si los enfermos acuden según una distribución de Poisson de tasa 3 llegadas por hora, determinar el tiempo medio que un paciente espera antes de pasar a la consulta y el que tarda en salir a la calle. Estudiar la longitud de la cola en función de la tasa de llegadas.

➤ Modelo M/D/1

Cuando el servicio consiste básicamente en la misma tarea rutinaria que el servidor realiza para todos los clientes tiende a haber poca variación en los tiempos de servicio requeridos, siendo éstos, por tanto, iguales a una constante $1/\mu$ (distribución de los tiempos de servicio *degenerada*). En una cola M/D/1 se supone, además, que la llegada es de Poisson de parámetro λ y que hay un único servidor.

En este caso, si $\rho < 1$, se tiene:

$$\begin{aligned} L_q &= \frac{\rho^2}{2(1-\rho)} & W_q &= \frac{\rho}{2\mu(1-\rho)} \\ L &= \rho + L_q & W &= \frac{1}{\mu} + W_q \end{aligned}$$

EJEMPLO DE COLA MODELO M/D/1

Un operario tarda exactamente 12 minutos (0,2 horas) en poner a punto un telar para que continúe tejiendo. Si cada hora se desarreglan en promedio 3 telares (averías según un proceso de Poisson), determinar el tiempo medio que un telar desajustado tarda en empezar a ser reparado.

